

Стоимость недвижимости

Кузнецов Г.И.

Введение

Разработка многофакторной модели для оценки стоимости недвижимости в заданном регионе на основе гибридных подходов с использованием языка программирования Python.

Задачи:

1. Собрать данные по стоимости недвижимости в выбранном регионе.
2. Выбрать признаки, влияющие на стоимость разных типов недвижимости в регионе.
3. Вдвинуть гипотезы о том, какие признаки наиболее и наименее влияют на стоимость разных типов недвижимости, проверить гипотезы.
4. Смоделировать модель прогнозирования стоимости разных видов недвижимости в выбранном регионе на основе разных методов обучения, сравнить эффективность моделей.
5. Дать рекомендации покупателям и продавцам недвижимости.

Сбор данных

Использовал CianParser и отфильтровал наиболее подходящие признаки.

Сохранил затем это в .csv файл, чтобы всегда можно было продолжить работу, не парся заново!

```
from cianparser import CianParser
import pandas as pd

parser = CianParser(location="Москва")

flats = parser.get_flats(
    deal_type="sale",
    rooms=(1, 2, 3),
    additional_settings={
        "start_page": 1,
        "end_page": 80,
        "only_flat": True,
        # "sort_by": "price_from_min_to_max"
    }
)

df = pd.DataFrame(flats)
df.to_csv("flats.csv", index=False, encoding="utf-8-sig")
```

Парсер

```
features = [
    "price",           # цена - таргет
    "district",        # район
    "underground",     # метро
    "street",          # улица
    "house_number",    # номер дома
    "floor",           # этаж
    "floors_count",    # этажей в доме
    "total_meters",    # общая площадь
    "rooms_count",     # комнаты
    "residential_complex", # название ЖК
    "url"              # ссылка (пригодится)
]

df = df[features]
df.to_csv("flats_cut.csv", index=False, encoding="utf-8-sig")
```

Выбор признаков

Предобработка

В основном, ограничился тем, что почистил NaN-значения, пытаюсь сохранить размер итак небольшого датасета.

```
df.isna().sum()
```

```
✓ 0.0s
```

```
price      30
district   99
underground    6
street     88
house_number  92
floor       0
floors_count  0
total_meters  0
rooms_count  0
residential_complex  567
url         0
dtype: int64
```

```
df.info()
```

```
✓ 0.0s
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 1246 entries, 1 to 1458
Data columns (total 11 columns):
#   Column                Non-Null Count  Dtype
---  -
0   price                 1246 non-null   float64
1   district              1246 non-null   object
2   underground           1246 non-null   object
3   street                1246 non-null   object
4   house_number          1246 non-null   object
5   floor                 1246 non-null   int64
6   floors_count          1246 non-null   int64
7   total_meters          1246 non-null   float64
8   rooms_count           1246 non-null   int64
9   residential_complex    1246 non-null   object
10  url                   1246 non-null   object
dtypes: float64(2), int64(3), object(6)
memory usage: 116.8+ KB
```

Гипотезы

Выдвинул несколько базовых гипотез и проверил их, смотря на корреляцию и некоторые другие показатели.

1. Чем больше общая площадь квартиры (total_meters), тем выше её цена.
2. Квартиры в центральных районах (district) стоят дороже, чем в спальных.
3. Близость к метро (underground) увеличивает стоимость квартиры.
4. Наличие жилого комплекса (residential_complex) повышает цену объекта.
5. Этаж (floor) почти не влияет на цену, если дом не высокий.
6. Название улицы (street) и номер дома (house_number) не влияют на цену.
7. Количество комнат (rooms_count) напрямую связано с ценой, но не линейно.

7. Количество комнат (rooms_count) напрямую связано с ценой, но не линейно.

```
# Гипотеза 1
corr_result = df[['total_meters', 'price']].dropna()
corr_coef, corr_p = pearsonr(corr_result['total_meters'], corr_result['price'])
print(f"1: {corr_coef}, {corr_p}")

# Гипотеза 2
anova_df = df[['district', 'price']].dropna()
district_groups = [g['price'].values for _, g in anova_df.groupby('district')]
anova_f_district, anova_p_district = f_oneway(*district_groups)
print(f"2: {anova_f_district}, {anova_p_district}")

# Гипотеза 3
anova_df2 = df[['underground', 'price']].dropna()
underground_groups = [g['price'].values for _, g in anova_df2.groupby('underground')]
anova_f_underground, anova_p_underground = f_oneway(*underground_groups)
print(f"3: {anova_f_underground}, {anova_p_underground}")

# Гипотеза 4: ANOVA по residential_complex
anova_df4 = df[['residential_complex', 'price']].dropna()
res_groups = [g['price'].values for _, g in anova_df4.groupby('residential_complex')]
anova_f_res, anova_p_res = f_oneway(*res_groups)
print(f"4: {anova_f_res}, {anova_p_res}")

# Гипотеза 5: Корреляция floor и price
corr_result_floor = df[['floor', 'price']].dropna()
corr_coef_floor, corr_p_floor = pearsonr(corr_result_floor['floor'], corr_result_floor['price'])
print(f"5: {corr_coef_floor}, {corr_p_floor}")

# Гипотеза 6: ANOVA для street и house_number
anova_df6a = df[['street', 'price']].dropna()
street_groups = [g['price'].values for _, g in anova_df6a.groupby('street')]
anova_f_street, anova_p_street = f_oneway(*street_groups)

anova_df6b = df[['house_number', 'price']].dropna()
house_groups = [g['price'].values for _, g in anova_df6b.groupby('house_number')]
anova_f_house, anova_p_house = f_oneway(*house_groups)
print(f"6: {anova_f_street}, {anova_p_street}, {anova_f_house}, {anova_p_house}")

# Гипотеза 7: rooms_count и price (ANOVA + корреляция)
anova_df7 = df[['rooms_count', 'price']].dropna()
rooms_groups = [g['price'].values for _, g in anova_df7.groupby('rooms_count')]
anova_f_rooms, anova_p_rooms = f_oneway(*rooms_groups)
corr_coef_rooms, corr_p_rooms = pearsonr(anova_df7['rooms_count'], anova_df7['price'])
print(f"7: {corr_coef_rooms}, {corr_p_rooms}")
```

Гипотезы: обоснование

Гипотеза 1:

Чем больше общая площадь (`total_meters`), тем выше цена $\rightarrow \text{corr} = 0.735, p \approx 2.8e-212$

Сильная положительная корреляция, связь очень значима — площадь сильно влияет на цену.

Гипотеза 2:

Квартиры в разных районах (`district`) отличаются по цене $\rightarrow F = 5.31, p \approx 4.28e-51$

Различия между районами статистически значимы, район влияет на цену.

Гипотеза 3:

Близость к метро (`underground`) влияет на цену $\rightarrow F = 3.90, p \approx 1.38e-52$ Метро оказывает значимое влияние на цену, по выборке.

Гипотеза 4:

Жилой комплекс (`residential_complex`) повышает цену $\rightarrow F = 5.75, p \approx 2.28e-91$

Наличие и тип ЖК значимо влияют на стоимость жилья.

Гипотеза 5:

Этаж (`floor`) почти не влияет на цену $\rightarrow \text{corr} = -0.099, p \approx 0.00044$

Связь слабая, но значимая, влияние небольшое и скорее обратное.

Гипотеза 6:

Название улицы (`street`) и номер дома (`house_number`) не влияют

`street`: $F = 9.05, p \approx 3.52e-149$

`house_number`: $F = 1.16, p \approx 0.031$

Улица заметно влияет на цену, а номер дома — незначительно, но чуть выше порога (0.05).

Гипотеза 7:

Количество комнат (`rooms_count`) влияет на цену, но не линейно $\rightarrow \text{corr} = 0.30, p \approx 2.2e-27$

Есть умеренная положительная связь, значимая, но она не строго линейная.

Моделирование

```
models = {  
    'Linear Regression': LinearRegression(),  
    'Decision Tree': DecisionTreeRegressor(random_state=42),  
    'Random Forest': RandomForestRegressor(random_state=42, n_estimators=100),  
    'Gradient Boosting': GradientBoostingRegressor(random_state=42, n_estimators=100)  
}  
results = {}
```

```
cat_features = ['district', 'underground', 'street', 'house_number', 'residential_complex']  
num_features = ['floor', 'floors_count', 'total_meters', 'rooms_count']  
  
preprocessor = ColumnTransformer([  
    ('num', Pipeline([  
        ('imputer', SimpleImputer(strategy='median')),  
        ('scaler', StandardScaler())  
    ]), num_features),  
    ('cat', Pipeline([  
        ('imputer', SimpleImputer(strategy='constant', fill_value='missing')),  
        ('onehot', OneHotEncoder(handle_unknown='ignore'))  
    ]), cat_features)  
])
```

```
X = df.drop(columns=['price', 'url'])  
y = df['price']
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

```
for name, model in models.items():  
    pipeline = Pipeline([  
        ('preprocessor', preprocessor),  
        ('regressor', model)  
    ])  
    pipeline.fit(X_train, y_train)  
    preds = pipeline.predict(X_test)  
    results[name] = {  
        'RMSE': mean_squared_error(y_test, preds),  
        'MAE': mean_absolute_error(y_test, preds),  
        'R2': r2_score(y_test, preds)  
    }
```

```
Linear Regression: RMSE=1587469629853561.75, MAE=22972264.25, R2=0.769  
Decision Tree: RMSE=2222047473859969.00, MAE=19837366.78, R2=0.676  
Random Forest: RMSE=996846489456414.50, MAE=16049866.48, R2=0.855  
Gradient Boosting: RMSE=757862874814894.62, MAE=15652485.62, R2=0.890
```

```
for name, metrics in results.items():  
    print(f"{name}: RMSE={metrics['RMSE']:.2f}, MAE={metrics['MAE']:.2f}, R2={metrics['R2']:.3f}")
```


Рекомендации

На основе датасета, анализа гипотез и результатов моделирования, предоставил несколько рекомендаций.

Для покупателей:

1. Цена напрямую связана с площадью — выбирайте квартиры, которые соответствуют вашим финансовым возможностям с учётом этой зависимости. Модель показывает сильную корреляцию, значит переплата за лишние метры — частое явление.
2. Обращайте внимание на район — из анализа и ANOVA ясно, что цена существенно варьируется в зависимости от района, так что если хотите сэкономить, рассмотрите варианты в менее дорогих районах, но с учётом инфраструктуры.
3. Близость к метро повышает стоимость, поэтому если бюджет ограничен, ищите квартиры чуть дальше от станций.
4. Жилой комплекс заметно влияет на цену, поэтому если модель прогнозирует высокую стоимость, проверьте наличие ЖК — это может быть причиной.
5. Этаж практически не влияет на цену (слабая отрицательная связь), так что не стоит переплачивать за «любимые» этажи.
6. Количество комнат влияет, но связь не линейна — больше комнат не всегда значит дороже, смотрите на соотношение цена/комнаты и площадь.

Для продавцов:

1. Используйте площадь и район как ключевые аргументы для цены, так как модель и анализ показывают их главную роль.
2. Подчеркивайте наличие жилого комплекса и близость к метро в объявлениях, т.к. они увеличивают стоимость.
3. Не переоценивайте влияние этажа, улицы или номера дома — модель показывает, что эти факторы значительно меньше влияют на цену.
4. Если квартира с большим количеством комнат, объясните покупателям ценность через площадь и функциональность, так как модель выявила сложную нелинейную связь.
5. Используйте модель, чтобы прогнозировать адекватную цену и быстрее закрыть сделку, избегая завышений или недооценок.

Выводы

- собраны и подготовлены данные по стоимости недвижимости в выбранном регионе;
- выбраны и проанализированы ключевые признаки, влияющие на цену различных типов недвижимости;
- сформулированы и проверены гипотезы о влиянии признаков на стоимость объектов;
- построены и обучены модели прогнозирования стоимости недвижимости с использованием разных алгоритмов, проведено сравнение их эффективности;
- разработаны практические рекомендации для покупателей и продавцов, основанные на результатах анализа и моделирования.

Спасибо за внимание